

# APLICACIÓN DE LOS ÍNDICES EN MODELOS BIFACTOR

Asignatura: Validez

---

Brian N. Peña-Calero  
Universidad Complutense de Madrid

11 marzo, 2025

# Evaluaciones de los índices en Bifactor

Rodriguez, Reise, y Haviland (2016) indica 3 aspectos interpretativos relevantes en los índices bifactor:

1. **¿Los puntajes totales reflejan variación en una sola variable latente?**  
(Indicadores:  $\omega$ ,  $\omega_H$ ); y, de forma relacionada, ¿los puntajes de subescala reflejan varianza confiable independiente del factor general? (Indicadores:  $\omega_S$ ,  $\omega_{HS}$ )
2. **¿Pueden los ítems usarse para especificar variables latentes en un contexto SEM?** Indicadores: FD, H
3. **¿Son las medidas esencialmente unidimensionales y, por lo tanto, deben especificarse como una única variable latente en SEM?**  
Indicadores: ECV, PUC

# Puntajes totales en un factor general o específicos

# Fiabilidad en la Teoría Clásica de los Test (TCT)

En la TCT, la fiabilidad de una medida se define como la proporción de la varianza observada que se debe a la **varianza verdadera**, excluyendo el error de medición. Se parte de la ecuación fundamental:

$$O = V + e$$

Donde:

- $O$  es la puntuación observada en un test
- $V$  es la puntuación verdadera
- $e$  es el error de medición

# Definición de Fiabilidad

Dado que la varianza de una suma de variables es:

$$\text{Var}(O) = \text{Var}(V) + \text{Var}(e) + 2\text{Cov}(V, e)$$

Y asumiendo en la TCT que el error es **aleatorio** y no está correlacionado con la puntuación verdadera ( $\text{Cov}(V, e) = 0$ ), tenemos:

$$\text{Var}(O) = \text{Var}(V) + \text{Var}(e)$$

# Definición de Fiabilidad

Por lo que la fiabilidad ( $\rho$ ) se expresa como:

$$\rho = \frac{\text{Var}(V)}{\text{Var}(O)} = \frac{\text{Var}(V)}{\text{Var}(V) + \text{Var}(E)}$$

Es decir, la proporción de la varianza de la puntuación observada que es atribuible a la varianza verdadera.

En el análisis factorial, se puede hacer la asunción que la carga factorial al cuadrado ( $\lambda^2 = h^2$ ) puede ser entendida como la  $\text{Var}(V)$ ; mientras que la unicidad ( $1 - \lambda^2 = 1 - h^2 = u$ ) puede ser considerado como la  $\text{Var}(E)$ .

# Puntajes Totales

Uno de los más reportados sería el  $\omega$ , que en un modelo bifactor, representa la varianza común atribuido a la suma del factor general y los factores específicos. *Un valor alto, refleja multidimensionalidad.*

$$\omega = \frac{\left(\sum \lambda_{\text{gen}}\right)^2 + \sum_{k=1}^K \left(\sum \lambda_{\text{grp}_k}\right)^2}{\left(\sum \lambda_{\text{gen}}\right)^2 + \sum_{k=1}^K \left(\sum \lambda_{\text{grp}_k}\right)^2 + \sum (1 - h^2)}$$

- $\lambda_{\text{gen}}$ : Cargas factoriales de los ítems sobre el **factor general**.
- $\lambda_{\text{grp}_k}$ : Cargas factoriales de los ítems sobre el **factor específico** (o grupo)
- $1 - h^2$ : Representa el error de medición.

# Puntajes Totales

En tanto, el  $\omega_H$  estudia esta varianza común pero solo la parte que se encuentra atribuída al Factor General, eliminando la parte de los factores específicos.

$$\omega_H = \frac{\left(\sum \lambda_{\text{gen}}\right)^2}{\left(\sum \lambda_{\text{gen}}\right)^2 + \sum_{k=1}^K \left(\sum \lambda_{\text{grp}_k}\right)^2 + \sum (1 - h^2)}$$

- $\lambda_{\text{gen}}$ : Cargas factoriales de los ítems sobre el **factor general**.
- $\lambda_{\text{grp}_k}$ : Cargas factoriales de los ítems sobre el **factor específico** (o grupo)
- $1 - h^2$ : Representa el error de medición.



# Puntajes Sub-Escala:

Estima la fiabilidad de la sub-escala contando la varianza común del factor general y del factor en específico. Habitualmente esto, podría ser alto y sería un peligro evaluarlo así.

$$\omega_S = \frac{\left(\sum \lambda_{\text{gen}}\right)^2 + \left(\sum \lambda_{k=1}\right)^2}{\left(\sum \lambda_{\text{gen}}\right)^2 + \left(\sum \lambda_{k=1}\right)^2 + \sum (1 - h^2)}$$

- $\lambda_{\text{gen}}$ : Cargas factoriales de los ítems sobre el **factor general**.
- $\lambda_{\text{grp}_k}$ : Cargas factoriales de los ítems sobre el **factor específico** (o grupo)
- $1 - h^2$ : Representa el error de medición.

# Puntajes Sub-Escala:

Este omega jerárquico evaluado en la sub-escala ( $\omega_{HS}$ ), indica que tanto de la varianza común del factor específico es únicamente del factor específico. *En un modelo bifactor que se sostiene, este indicador debería ser bajo.*

$$\omega_{HS} = \frac{\left(\sum \lambda_{\text{grp}_k}\right)^2}{\left(\sum \lambda_{\text{gen}}\right)^2 + \sum_{k=1}^K \left(\sum \lambda_{\text{grp}_k}\right)^2 + \sum (1 - h^2)}$$

- $\lambda_{\text{gen}}$ : Cargas factoriales de los ítems sobre el **factor general**.
- $\lambda_{\text{grp}_k}$ : Cargas factoriales de los ítems sobre el **factor específico** (o grupo)
- $1 - h^2$ : Representa el error de medición.

# Interpretaciones e indicaciones

- Instrumentos modelados de forma unifactorial pueden presentar una estimación de fiabilidad  $\omega$  muy alta, a pesar de que ese único factor podría tener un ajuste cuestionable o no estar representando realmente un único factor.
- De forma similar sucederían en los modelos multifactoriales, en los que las estimaciones de sus factores ( $\omega_s$ ) presenten valores altos, a pesar de que un gran % de esa  $\psi_{S_k}$  realmente sean exactamente los mismos en los otros factores (un factor general no modelado).
- Los modelos bifactor pueden contemplar FE's que no contengan  $\psi_{S_k}$  suficiente para ser interpretados individualmente ( $\omega_{HS}$  bajo con respecto a  $\omega_s$ ), pero que a la vez contengan suficiente  $\psi_{S_k}$  para tener que modelarlos y no prescindir de su especificación factorial.

# Especificaciones de los modelos en contexto SEM

# Índices de FD y H

Para evaluar si los ítems son adecuados para definir variables latentes en un modelo SEM, se utilizan:

- **Factor Determinacy (FD):**  
Mide la correlación entre los puntajes estimados y la verdadera variable latente.

$$FD = \text{diag}\left(\Phi \Lambda^T \Sigma^{-1} \Lambda \Phi\right)^{\frac{1}{2}}$$

- Valores altos ( $\geq 0.90$ ) indican que el factor está medido con excelente precisión
- Valores moderados (0.70–0.80) pueden considerarse aceptables para algunas aplicaciones

# Índices de FD y H

Para evaluar si los ítems son adecuados para definir variables latentes en un modelo SEM, se utilizan:

- **Índice H (Construct Replicability):**  
Cuan bien está definido el constructo a partir de sus indicadores.

$$H = \frac{1}{1 + \frac{1}{\sum_{i=1}^k \frac{\lambda_i^2}{1 - \lambda_i^2}}}$$

- Se suele considerar un valor  $H \geq 0.80$  como indicador de un constructo robusto.
- Se considera  $H \geq 0.70$  como aceptable

# Interpretaciones e indicaciones

- En un modelo SEM, solo se debería modelar factores específicos en los que tanto H como FD sean al menos  $\geq 0.70$ .
- Una alternativa a esto, es modelar la escala como *esencialmente unidimensional*.
- Aunque el índice H pueda ser un buen indicador hay que prestar atención a las cargas factoriales de los ítems. Podría ser que el factor esté siendo modelado únicamente por una parte de ellos.
- Cargas factorialmente inusualmente altas (por ej. 0.80, 0.90, 0.30, 0.35, 0.28), podría estar debiéndose a algo distinto al factor específico al que pertenece, y no debería confiarse en las estimaciones del índice H o FD.

# Unidimensionalidad esencial



# Índices ECV y PUC

Para determinar si la medida puede tratarse como esencialmente unidimensional, se utilizan:

- **Explained Common Variance (ECV):**

$$\text{ECV} = \frac{\sum \lambda_{\text{gen}}^2}{\sum \lambda_{\text{gen}}^2 + \sum_{k=1}^K \sum \lambda_{\text{grp}_k}^2}$$

- Un valor alto (> .70 o .80) sugiere que la mayor parte de la varianza común se debe al factor general.
- Valores cercanos a 1 indican unidimensionalidad suficiente.
- Valores bajos probablemente se asocian a que una estructura multidimensional pueda explicar mejor los datos.

# Índices ECV y PUC

Para determinar si la medida puede tratarse como esencialmente unidimensional, se utilizan:

- **Percentage of Uncontaminated Correlations (PUC):**  
% de correlaciones entre ítems debido únicamente al factor general.

$$\text{PUC} = 1 - \frac{\# \text{ de correlaciones entre ítems del mismo factor}}{\# \text{ total de correlaciones}}$$

- Un PUC elevado (por ejemplo, > 0.80) refuerza la interpretación unidimensional.
- Valores cercanos a 1 indican unidimensionalidad suficiente.
- Valores bajos probablemente se asocian a que una estructura multidimensional pueda explicar mejor los datos.

# Interpretaciones e indicaciones

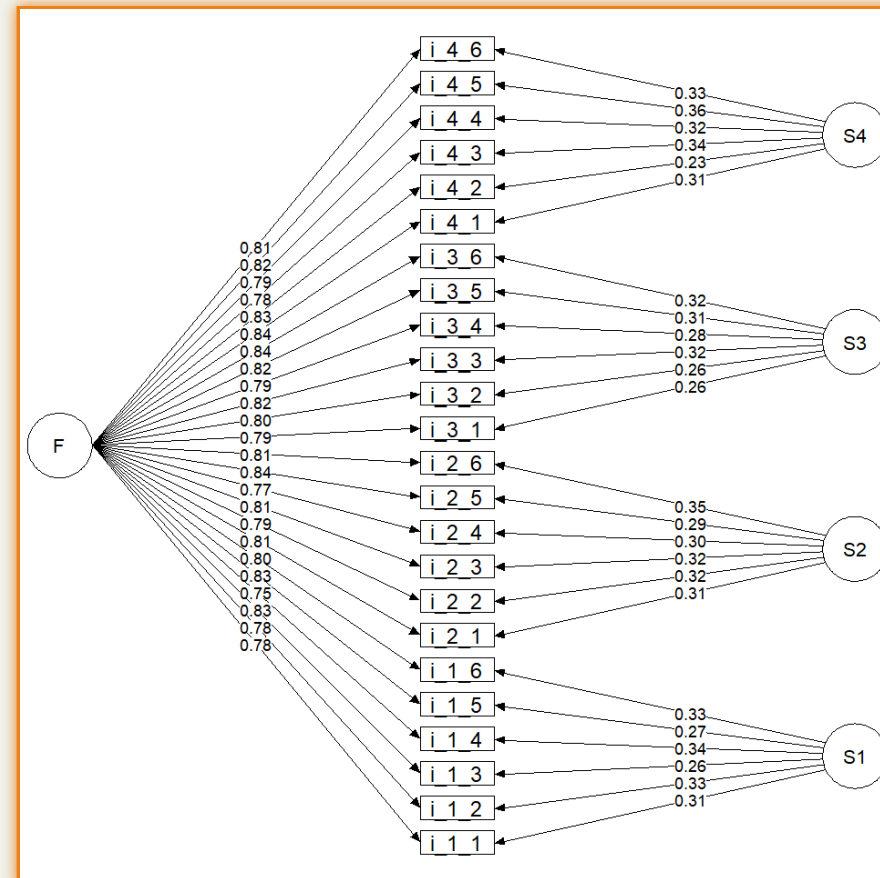
- En contexto SEM, algunos instrumentos pueden tratarse/especificarse de forma unidimensional sin cometer un sesgo relevante en las estimaciones de las cargas factoriales. Esto se ve apoyado cuando ECV y PUC > .70.
- En la revisión de Rodríguez, Reise, y Haviland (2016) observan que incluso cuando ECV se encuentra entorno a .50, si PUC es alto, podría tratarse el instrumento de forma unidimensional sin cometer un sesgo importante.
- PUC puede sobre-estimarse cuando se tiene muchos FE's y pocos ítems en cada uno

# Ejemplificación de un Bifactor Perfecto

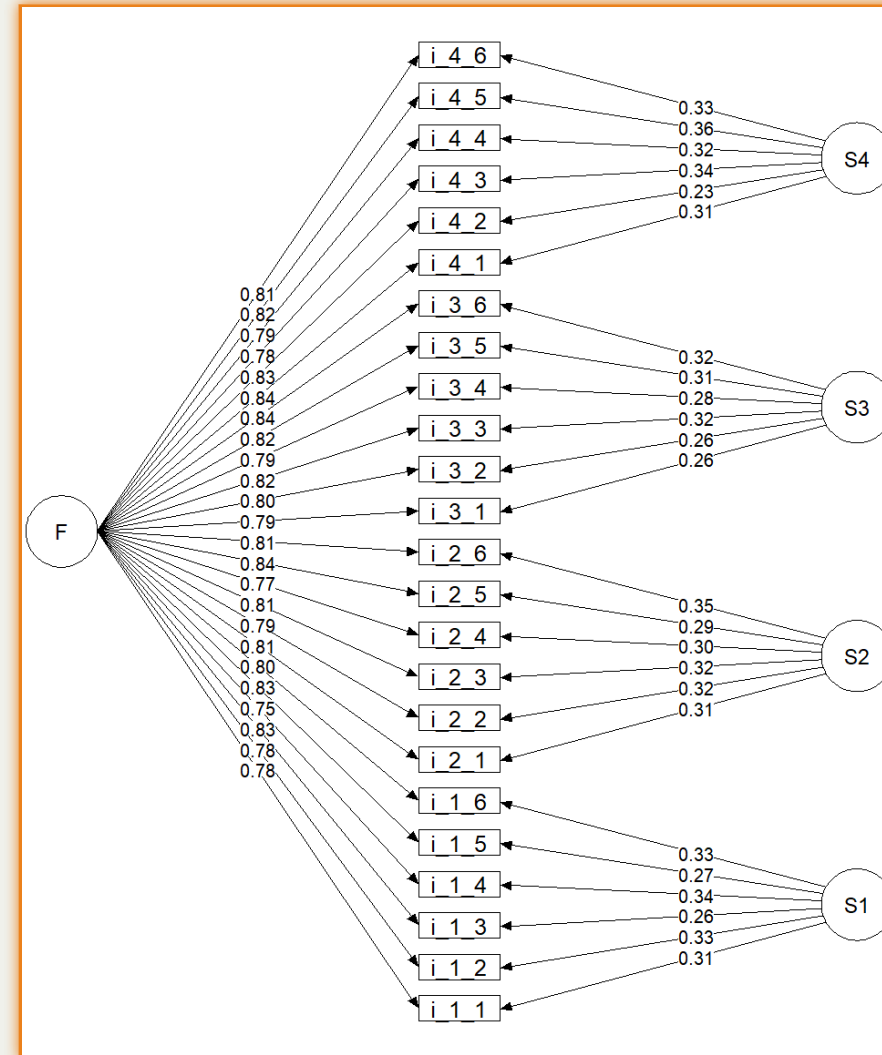
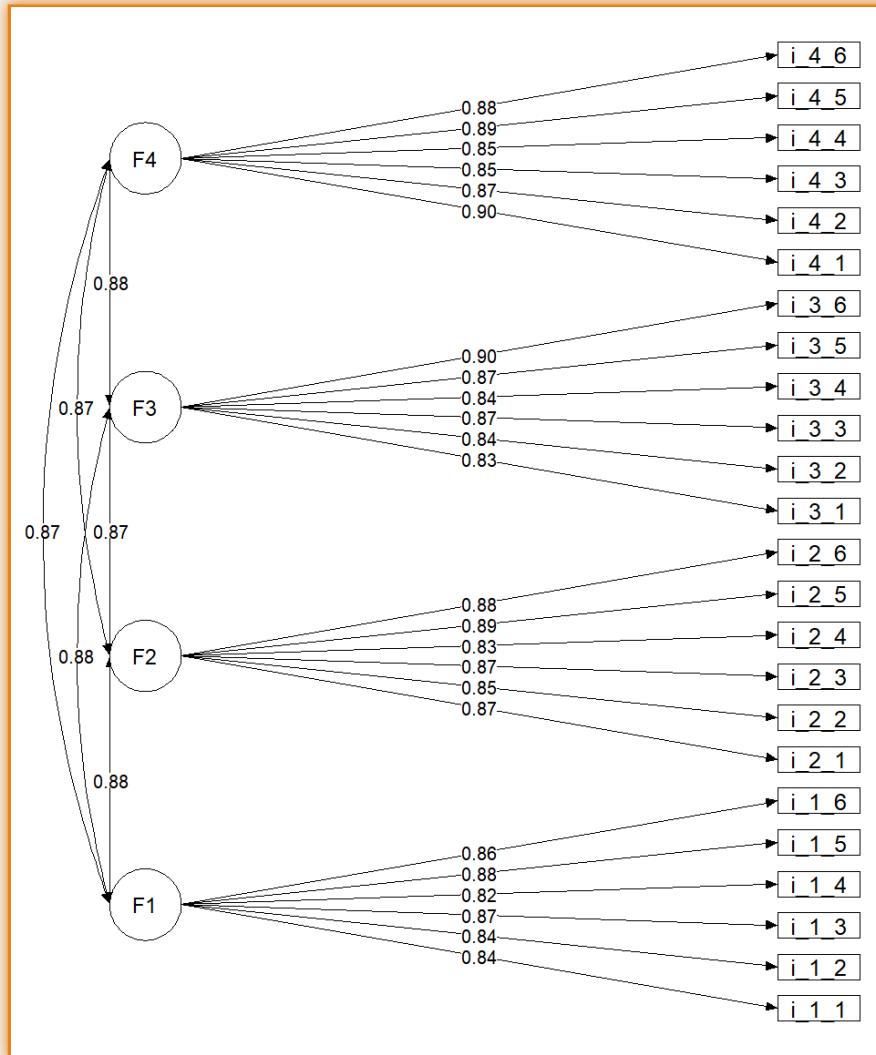
# Ejemplificación

Con una muestra suficiente, 4 factores con 6 ítems en cada factor y un buen comportamiento bifactorial.

```
1 library(lavaan)
2 library(semPlot)
3 library(BifactorIndicesCalculator)
4 source("simulaBifactor.R")
5
6 result_ideal <- simulaBifactor(
7   sampleSize = 1000,
8   nFactors = 4,
9   itemsPerFactor = 6,
10  loadingGeneral = 0.8,
11  loadingSpecific = 0.3,
12  fluctuation = 0.05,
13  type_problematic = "perfect",
14  estimator = "MLR"
15 )
```



# ¿Y si fuera multifactorial?



# Solución multifactorial

```
1 summary(result_ideal$fit_multi, fit.measures = TRUE, standardized = TRUE)
```

lavaan 0.6-19 ended normally after 39 iterations

Estimator	ML
Optimization method	NLMINB
Number of model parameters	54
Number of observations	1000

Model Test User Model:

	Standard	Scaled
Test Statistic	259.862	261.970
Degrees of freedom	246	246
P-value (Chi-square)	0.260	0.231
Scaling correction factor		0.992
Yuan-Bentler correction (Mplus variant)		

# Solución multifactorial

```
1 summary(result_ideal$fit_bifactor, fit.measures = TRUE, standardized = TRUE)
```

lavaan 0.6-19 ended normally after 35 iterations

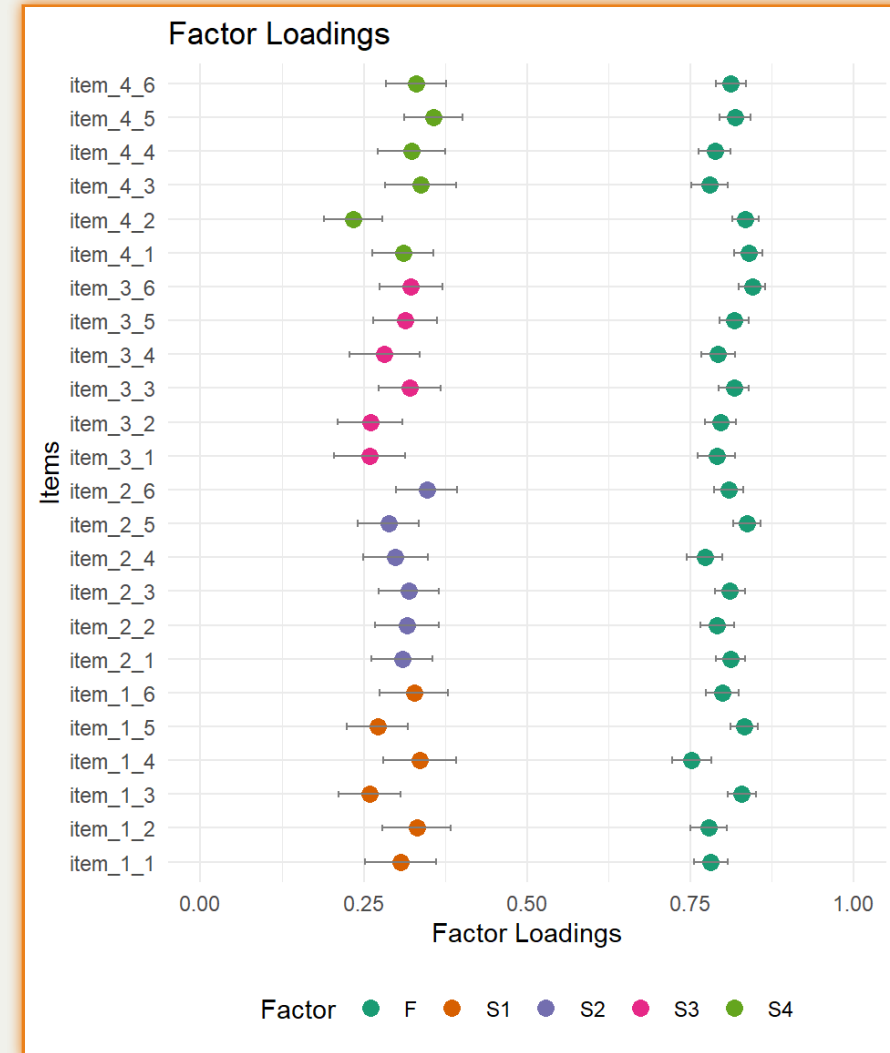
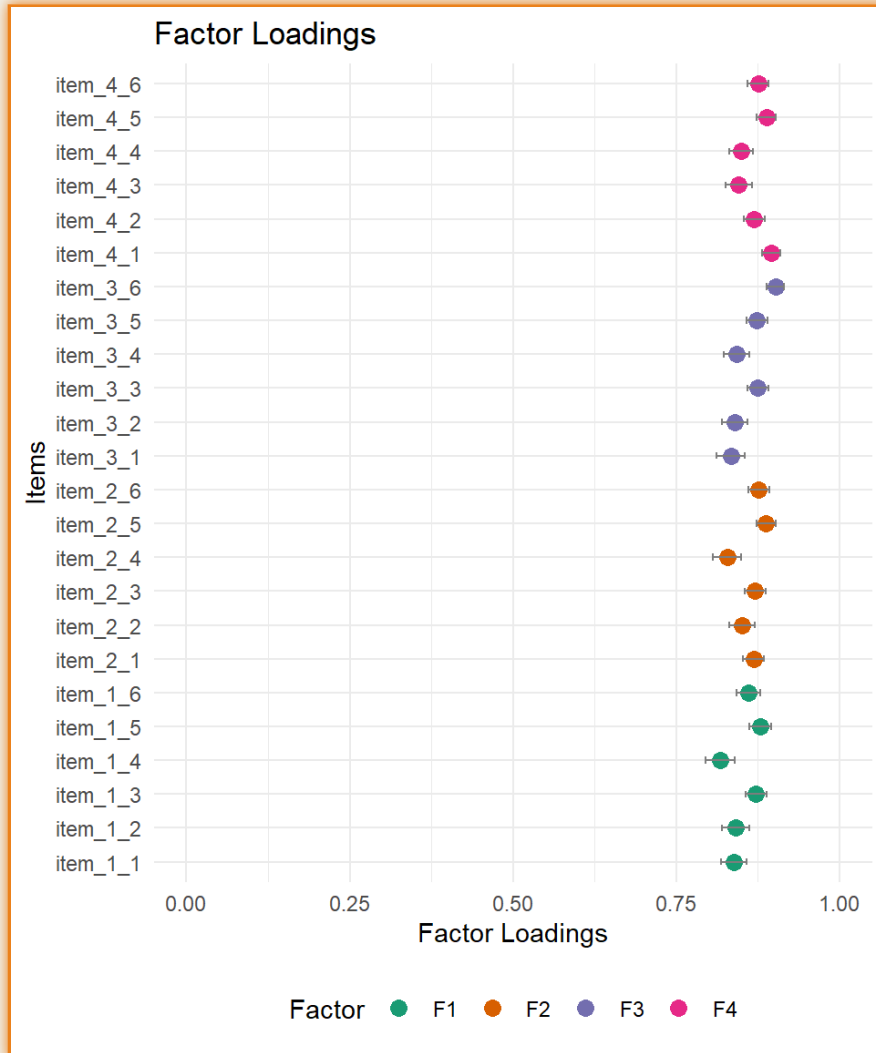
Estimator	ML
Optimization method	NLMINB
Number of model parameters	72
Number of observations	1000

Model Test User Model:

	Standard	Scaled
Test Statistic	218.905	221.095
Degrees of freedom	228	228
P-value (Chi-square)	0.656	0.616
Scaling correction factor		0.990
Yuan-Bentler correction (Mplus variant)		



# Organización de las cargas factoriales



# Obtención de Índices

```
1 bifactorIndices(result_ideal$fit_bifactor, UniLambda = result_ideal$fit_uni)
```

```
$ModelLevelIndices
```

	ECV.F	PUC	Omega.F	OmegaH.F	ARPB
	0.87250776	0.78260870	0.98438334	0.94996921	0.01564634

```
$FactorLevelIndices
```

	ECV_SS	ECV_SG	ECV_GS	Omega	OmegaH	H	FD
F	0.8725078	0.87250776	0.8725078	0.9843833	0.9499692	0.9783633	0.9753907
S1	0.1292968	0.03159233	0.8707032	0.9410352	0.1208026	0.3847117	0.7239138
S2	0.1314340	0.03298034	0.8685660	0.9464750	0.1240935	0.3954727	0.7380738
S3	0.1164400	0.02903263	0.8835600	0.9451736	0.1092838	0.3628306	0.7176394
S4	0.1326829	0.03388694	0.8673171	0.9499120	0.1244707	0.4037519	0.7475393

```
$ItemLevelIndices
```

	IECV	RelParBias
item_1_1	0.8663711	0.014460658

```
item_1_2 0.8468884 0.017433707
```

# ¿Unidimensionalidad tiene sentido?

```
1 summary(result_ideal$fit_uni, fit.measures = TRUE, standardized = TRUE)
```

lavaan 0.6-19 ended normally after 19 iterations

Estimator	ML
Optimization method	NLMINB
Number of model parameters	48
Number of observations	1000

Model Test User Model:

	Standard	Scaled
Test Statistic	2606.856	2634.837
Degrees of freedom	252	252
P-value (Chi-square)	0.000	0.000
Scaling correction factor		0.989
Yuan-Bentler correction (Mplus variant)		

# ¿Unidimensionalidad tiene sentido?

```
1 modificationindices(result_ideal$fit_uni,  
2                       maximum.number = 10,  
3                       sort. = TRUE)
```

	lhs	op	rhs	mi	epc	sepc.lv	sepc.all	sepc.nox
314	item_4_1	~~	item_4_5	105.803	0.098	0.098	0.344	0.344
283	item_3_3	~~	item_3_6	105.581	0.097	0.097	0.344	0.344
325	item_4_5	~~	item_4_6	94.935	0.101	0.101	0.324	0.324
298	item_3_5	~~	item_3_6	85.588	0.089	0.089	0.309	0.309
235	item_2_5	~~	item_2_6	84.443	0.090	0.090	0.306	0.306
322	item_4_3	~~	item_4_6	79.879	0.101	0.101	0.295	0.295
177	item_2_1	~~	item_2_6	79.558	0.092	0.092	0.296	0.296
208	item_2_3	~~	item_2_6	78.026	0.092	0.092	0.293	0.293
321	item_4_3	~~	item_4_5	76.247	0.097	0.097	0.289	0.289
313	item_4_1	~~	item_4_4	75.223	0.088	0.088	0.288	0.288

# Comparación de ajustes

```
1 psymetrics::compare_model_fit(  
2   result_ideal$fit_uni,  
3   result_ideal$fit_multi,  
4   result_ideal$fit_bifactor  
5 )
```

MODEL	NOBS	ESTIMATOR	NPAR	Chi2	Chi2_df
result_ideal\$fit_uni	1000	MLR	48	2634.837	252
result_ideal\$fit_multi	1000	MLR	54	261.970	246
result_ideal\$fit_bifactor	1000	MLR	72	221.095	228

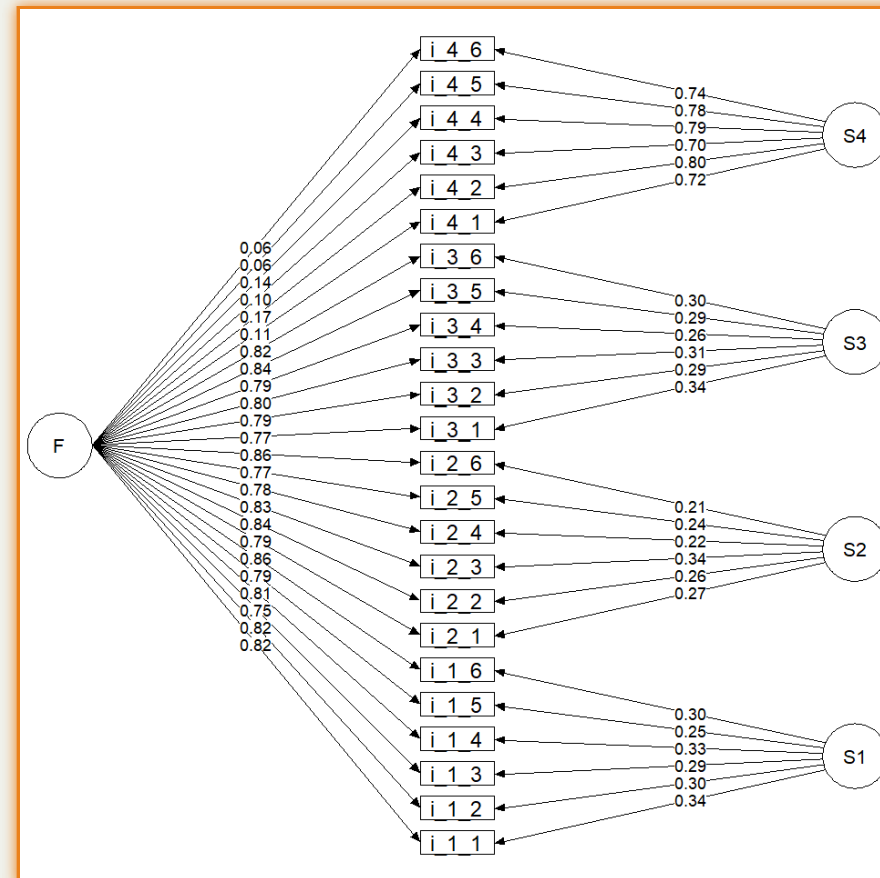
MODEL	p (Chi2)	CFI	TLI	RMSEA	RMSEA CI	SRMR
result_ideal\$fit_uni	< .001	0.906	0.897	0.097	[0.094, 0.101]	0.038
result_ideal\$fit_multi	0.231	0.999	0.999	0.008	[0.000, 0.016]	0.012
result_ideal\$fit_bifactor	0.616	1.000	1.000	0.000	[0.000, 0.012]	0.009

# Ejemplificación de un Bifactor con FE dominante

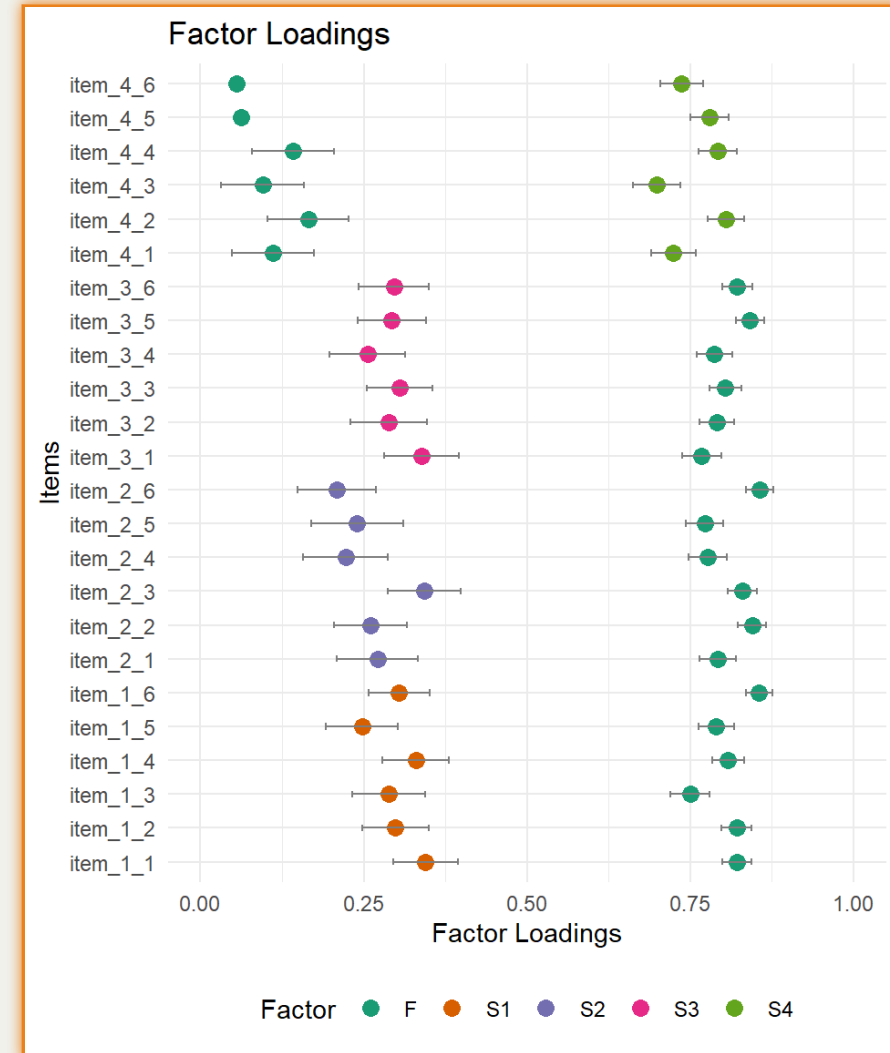

# Ejemplificación

Con una muestra suficiente, 4 factores con 6 ítems en cada factor y un buen comportamiento bifactorial.

```
1 result_1f <- simulaBifactor(  
2   sampleSize = 1000,  
3   nFactors = 4,  
4   itemsPerFactor = 6,  
5   loadingGeneral = 0.8,  
6   loadingSpecific = 0.3,  
7   fluctuation = 0.05,  
8   type_problematic = "1f",  
9   mod_gen_factor = 0.15,  
10  mod_spec_factor = 2.5,  
11  estimator = "MLR"  
12 )
```



# Organización de las cargas factoriales





# Obtención de Índices

```
1 bifactorIndices(result_1f$fit_bifactor, UniLambda = result_1f$fit_uni)
```

```
$ModelLevelIndices
```

	ECV.F	PUC	Omega.F	OmegaH.F	ARPB
	0.70564532	0.78260870	0.97275756	0.86241389	0.03276995

```
$FactorLevelIndices
```

	ECV_SS	ECV_SG	ECV_GS	Omega	OmegaH	H	FD
F	0.70564532	0.70564532	0.70564532	0.9727576	0.86241389	0.9721486	0.9705498
S1	0.12377861	0.03305574	0.87622139	0.9459541	0.11618284	0.3798054	0.7092911
S2	0.09359639	0.02442729	0.90640361	0.9412326	0.08600959	0.3071786	0.6467970
S3	0.12061010	0.03162232	0.87938990	0.9423015	0.11307017	0.3680375	0.6925122
S4	0.97843528	0.20524934	0.02156472	0.8939206	0.87694498	0.8925204	0.9461048

```
$ItemLevelIndices
```

	IECV	RelParBias
item_1_1	0.850379317	0.028620201

# Desajuste del unidimensional

```
1 summary(result_1f$fit_uni, fit.measures = TRUE, standardized = TRUE)
```

lavaan 0.6-19 ended normally after 27 iterations

Estimator	ML
Optimization method	NLMINB
Number of model parameters	48
Number of observations	1000

Model Test User Model:

	Standard	Scaled
Test Statistic	4604.696	4604.680
Degrees of freedom	252	252
P-value (Chi-square)	0.000	0.000
Scaling correction factor		1.000
Yuan-Bentler correction (Mplus variant)		

# Comparación de ajustes

```
1 psymetrics::compare_model_fit(  
2   result_1f$fit_uni,  
3   result_1f$fit_multi,  
4   result_1f$fit_bifactor  
5 )
```

MODEL	NOBS	ESTIMATOR	NPAR	Chi2	Chi2_df
result_1f\$fit_uni	1000	MLR	48	4604.680	252
result_1f\$fit_multi	1000	MLR	54	284.945	246
result_1f\$fit_bifactor	1000	MLR	72	245.710	228

MODEL	p (Chi2)	CFI	TLI	RMSEA	RMSEA CI	SRMR
result_1f\$fit_uni	< .001	0.794	0.775	0.131	[0.128, 0.135]	0.131
result_1f\$fit_multi	0.045	0.998	0.998	0.013	[0.002, 0.019]	0.022
result_1f\$fit_bifactor	0.201	0.999	0.999	0.009	[0.000, 0.016]	0.015

# References

Rodriguez, Anthony, Steven P. Reise, y Mark G. Haviland. 2016. «Applying Bifactor Statistical Indices in the Evaluation of Psychological Measures». *Journal of Personality Assessment* 98 (3): 223-37.

<https://doi.org/10.1080/00223891.2015.1089249>.